

基于多源数据融合的旅客画像构建方法研究

张峥嵘¹ 李驭涛¹ 董博²

(1. 广州地铁集团有限公司 广州 510000)

(2. 广州佳都智通科技有限公司 广州 510000)

摘要:文章基于多源异构数据融合,构建了覆盖身份属性、出行行为及消费特征的动态旅客画像因子体系。通过因子独立性检验与高维组合分析,实现对旅客群体行为的精准刻画与时序动态追踪。以某省域铁路局2023年度客票及行为数据为例,验证了所提方法在旅客分类和趋势捕捉上的有效性,实验结果表明,所构建的旅客画像能够清晰区分不同类型用户,准确反映其出行行为特征及变化趋势,具备较强的稳定性和泛化能力。

关键词:多源数据融合;旅客画像;行为建模;因子体系

中图分类号: TP311.13; U293

文献标识码: B

文章编号: 260108-13468

Research on Passenger Profiling Method Based on Multi-source Data Fusion

Zhang Zhengrong¹ Li Yutao¹ Dong Bo²

(1 Guangzhou Metro Group Co., Ltd., Guangzhou 510000, China)

(2. PCI Technology & Service Co., Ltd., Guangzhou 510000, China)

Abstract: Based on multi-source heterogeneous data fusion, this paper constructs a dynamic passenger profiling factor system covering identity attributes, travel behaviors, and consumption characteristics. Through factor independence testing and high-dimensional combination analysis, precise characterization and time-series dynamic tracking of passenger group behaviors are achieved. Taking the 2023 annual ticketing and behavior data of a provincial railway bureau as a case study, the effectiveness of the proposed method in passenger classification and trend capture is verified. Experimental results show that the constructed profiling system can clearly distinguish different types of users, accurately reflect their travel behavior characteristics and trends, and demonstrate strong stability and generalization capability.

Keywords: multi-source data fusion; passenger profiling; behavior modeling; factor system

1 旅客画像特征因子体系

1.1 旅客画像标签特征提取

为有效刻画旅客行为差异,文章从多源数据中提取关键特征因子,建立高维度、可演化的标签体系。与金融领域依赖财务与市场数据构建因子不同,旅客画像更侧重于个体内部属性与行为轨迹的深度建模,涵盖基本身份信息、出行偏好、消费能力、行程频率、路径选择等多类型特征^[1]。

设旅客画像特征空间为向量集合:

$$F = \{f_1, f_2, \dots, f_n\} \quad (1)$$

其中,每一维 f_i 对应一个特征因子,例如年龄段、出发地类型、车次等级偏好、出行时间段等。在数据预处理阶段,通过清洗、标准化与离散化操作,将每个因子划分为若干子区间。以因子 f_i 为例,其被划分为 m_i 个特征子集,即:

$$f_i = \{s_{i1}, s_{i2}, \dots, s_{im_i}\} \quad (2)$$

多因子交叉后构成最小单元数据集。每一个旅客样本 x 表示为:

$$x = (s_{1j}, s_{2k}, \dots, s_{nl}), \text{ 其中 } s_{ij} \in f_i \quad (3)$$

在高维空间内形成 $m_1 \times m_2 \times \dots \times m_n$ 个最小“因子类”单元^[2]。每一因子类的值 $v_{ijk\dots}$ 表示在该多因子组合区间内的旅客数量或出行次数。通过对这些因子类在不同时间维度上的分布变化进行观测,初步捕捉行为特征的动态模式^[3]。

为了进一步提炼画像结构的核心动因,需对这些因子类进行聚类分析与趋势建模。设某时间序列区间为:

$$T = \{t_1, t_2, \dots, t_k\} \quad (4)$$

对应因子类的变动函数为 $v(t)$,采用滑动窗口对其进行局部线性拟合,并引入波动率度量函数:

$$\sigma_i = \sqrt{\frac{1}{k} \sum_{j=1}^k (v_i(t_j) - \bar{v}_i)^2} \quad (5)$$

其中, $\bar{v}_i$ 为第 i 个因子类在时段 T 内的平均出行量。波动性高、呈现周期性或突变性特征的因子类将被视为“主力因子类”, 它们可显著影响整体客流走势。基于因子权重向上归集提取驱动性因子集合 $D \subset F$, 并结合市场实际运行轨迹进行对照, 建立因子与市场反馈的解释通道, 实现“标签—行为—市场”的三维联动建模^[4]。

1.2 多数据选择

旅客画像的核心不在于构建标签的数量, 而在于识别哪些特征变量能够显著揭示行为规律、驱动出行决策。因此, 因子构建的第一步是数据选择, 即从多种异构数据中筛选出具备代表性、区分性与可观测性的要素, 构建信息融合、粒度适中的特征体系。设数据源集合为:

$$D = \{D_1, D_2, \dots, D_m\} \quad (6)$$

其中, D_1 表示客票系统数据, 包含出发地、到达地、车次、购票时间、票价、席别等静态交易信息; D_2 表示身份注册与实名验证信息, 包括年龄、性别、常住地等; D_3 为 APP 行为数据, 如购票渠道、页面停留时间、改签记录等; D_4 为进出站行为轨迹; D_5 为客服与交互记录, 用于补充非结构化意图表达。

依据“差异性高、覆盖度高、变量独立、可融合性好”的原则, 构建以下五类核心标签因子:

(1) 固相因子(如年龄)表示旅客不随时间变化的稳定属性。将年龄因子 f_1 划分为四个区间:

$$f_1 = \begin{cases} Y_1, & 0 < \text{age} \leq 20 \\ Y_2, & 20 < \text{age} \leq 40 \\ Y_3, & 40 < \text{age} \leq 60 \\ Y_4, & \text{age} > 60 \end{cases} \quad (7)$$

(2) 籍住因子 f_2 , 反映旅客的流动性。通过对比籍贯地和常住地, 构建二值逻辑变量:

$$f_2 = \begin{cases} J_1, & \text{hometown} = \text{residence} \\ J_2, & \text{hometown} \neq \text{residence} \end{cases} \quad (8)$$

此因子可识别典型“候鸟型”人群, 如返乡探亲、季节性务工旅客。

(3) 频数因子 f_3 , 基于指定时段内的出行频次 n 进行划分, 衡量用户活跃度:

$$f_3 = \begin{cases} P_1, & n = 1 \\ P_2, & n = 2 \\ P_3, & 3 \leq n \leq 4 \\ P_4, & 5 \leq n \leq 9 \\ P_5, & n \geq 10 \end{cases} \quad (9)$$

也可用总里程或累计消费替代频次, 以刻画价值用户分布。

(4) 行迹因子 f_4 , 用于反映出行范围的地理层级。设出行目的地的行政级别为 u , 定义如下:

$$f_4 = \begin{cases} X_1, & \text{省内} \\ X_2, & \text{邻省} \\ X_3, & \text{跨省} \end{cases} \quad (10)$$

其中, 邻省划分结合实际出行联系紧密程度进行微调。

(5) 消费层因子 f_5 , 以旅客实际运价率 r 为依据, 用四分位法进行区间划分:

$$f_5 = \begin{cases} Z_1, & r < Q_1 \\ Z_2, & Q_1 \leq r < Q_2 \\ Z_3, & Q_2 \leq r < Q_3 \\ Z_4, & r \geq Q_3 \end{cases} \quad (11)$$

相较于席别, 这一连续变量更能真实反映旅客的消费层级与溢价承受能力。

通过上述因子构建, 实现了对用户自然属性、社会背景、行为意图与消费行为的系统编码。

2 基于多源数据融合的旅客画像构建

2.1 旅客画像数据检验

在构建旅客画像特征因子体系过程中, 必须保持各因子间的独立性。因子间若存在高度相关性, 将在后续交叉建模中引入结构性干扰, 导致画像标签失真或冗余膨胀, 降低模型解释力与泛化能力。因此, 在特征提取完成后, 文章对各因子间的独立性进行系统性检验, 确保最终建模变量满足统计前提。

在操作层面, 按年度划分样本集, 对每一一年内旅客在因子 A 和因子 B 各自分类下的组合分布进行统计。若检验结果中 $p \geq 0.05$, 则认为该对因子在统计意义上不相关, 可保留在后续模型中并参与因子交叉; 若 $p < 0.05$, 说明两个变量之间存在显著相关性, 需要进一步判断是弱相关还是冗余, 避免交互项重复表达旅客同一特征维度。

通过该检验方法, 有效识别潜在的因子间重合区域, 为旅客画像体系建立提供数据结构上的合理性支撑。

2.2 旅客画像数据量化分析

完成画像因子的结构定义与独立性检验后, 下一步对特征空间中的旅客样本进行定量刻画, 提炼出可计算、可聚合、可分析的核心指标体系。对单因子维度下的旅客分布进行归一化处理; 对于样本在多个因子维度的组合分布, 采用交叉因子类统计

进行高维空间切片分析。构建时间序列矩阵,记录各因子类在不同时间窗下的出行总量,结合滑动窗口与指数平滑算法,提取画像随时间变化的动态轨迹,从而区分出具有稳定、季节性或突发性特征的用户群体。

3 实验研究

选取某省域铁路局2023年度完整客票系统数据作为主数据源,结合旅客实名信息、进站行为记录及APP购票行为数据,构建统一的多源样本库。数据总样本量约为85万条,覆盖全年春运、暑运与节假日高峰周期。选取年龄、出行频次、消费层级、行程距离与籍贯迁移关系5个核心特征因子进行分析,分别离散为4~5个区间。标签体系构建后基于组合空间生成约240个有效因子类单元。辅助以可视化方式对不同用户画像进行行为轮廓比对,实验结果如图1所示:




图1 行为轮廓比实验结果

图1中三个明显分离的用户群体分别对应于在“消费能力—出行频次”二维特征空间中表现出不同行为特征的旅客类别。由图1可知,各类旅客画像轮廓清晰,无明显重叠,表明所选因子具备良好的区分性。中心聚集密集、边缘分布稀疏,说明聚类结构稳定,噪声控制较好。该实验结果验证了旅客标签因子经过标准化、交叉组合和独立性检验后,能够有效支持高质量的用户分层。动态轨迹追踪实验结果如图2所示。

由图2的趋势走势可以明显看出:高频商务类旅客出行高度稳定,全年波动小但在6~9月略有上升,显示出典型的商务出行刚需特征;通勤稳定类旅客保持中等强度的出行频次,全年趋势平滑,符合区域性日常通勤用户的画像;季节旅游类旅客




图2 动态轨迹追踪实验结果

呈现出典型的假期集中出行特征,暑期与节假日节点峰值明显,其余月份出行极少。

这一结果进一步验证了文章基于多源数据融合的旅客画像构建方法能够有效捕捉用户出行行为的时序特征,建立起“标签—行为—趋势”的动态模型,具备高度可用性与解释力。

4 结语

文章提出的基于多源数据融合的旅客画像构建方法,突破了传统静态标签的局限,实现了旅客行为的动态感知与深度建模。通过系统性的数据筛选、因子设计及独立性检验,构建了具备高区分度和解释力的画像体系,能够精准反映旅客多维行为特征及其时序变化。

参考文献

- [1] 贺馨仪,董明,刘文君,等.面向调控领域多源数据融合的电力变压器态势感知与预警方法研究[J].电工电能新技术,2023,42(04):48-58.
- [2] 陈宏,蒋文贤,黄丽萍,等.无线传感网络多源数据特征融合方法研究[J].传感技术学报,2024,37(12):2131-2136.
- [3] 陈文青,董绍华,刘洪艳,等.基于多源数据融合的油气联合站风险预警研究[J].武汉理工大学学报(信息与管理工程版),2023,45(02):212-217+223.
- [4] 吴欣玥,廖家仪,张晓荣.基于多源数据融合的成都市职住空间特征及影响因素研究[J].规划师,2023,39(01):120-127.
- [5] 刘祥波,王森,延凯,等.基于多源数据融合的配电网拓扑识别方法研究[J].自动化仪表,2024,45(03):59-63+69.

作者简介

张嵘嵘(1984.8-),男,汉族,广东广州人,研究生,高级工程师,研究方向:轨道交通清分数据中心、信息系统、大数据及云计算等;

李取涛(1976.8-),男,汉族,河南鄢陵人,本科,中级工程师,研究方向:轨道交通机电、自动化;

董博(2003.4-),男,汉族,河北保定人,本科,研究方向:市域及城际客票系统、智慧安检等。